

Energetická optimalizácia inteligentnej budovy

Bc. Lukáš Proner

Fakulta informatiky a elektrotechniky
Technická univerzita v Košiciach
Katedra počítačov a informatiky
Košice, Slovensko

Bc. Peter Balog

Fakulta informatiky a elektrotechniky
Technická univerzita v Košiciach
Katedra počítačov a informatiky
Košice, Slovensko

Abstract—Prispevok sa venuje ulohe energetickej optimalizácie inteligentnej budovy na základe predpovedi počasia a obsadenosti miestnosti. Zadanie odporuča využiť algoritmy Q-learning a DDPG a po ich implementácii porovnať ich prevádzkové vlastnosti z pohľadu úspor energie oproti fixnej strategii, vplyvu rôznych reward funkcií na výsledok a času potrebného na dosiahnutie stabilného riešenia. Predkladaný text sa zameriava primárne na vetvu riešenia založenú na Q-learningu, zatiaľ čo algoritmus DDPG je implementovaný paralelne v rámci súvisiacej časti projektu.

Index Terms—CityLearn, energetická optimalizácia, Q-learning, DDPG, obsadenosť, predpoveď počasia, inteligentná budova

I. Introduction

Energetická optimalizácia inteligentných budov predstavuje v súčasnosti významnú výzvu, najmä z hľadiska znižovania odberu elektrickej energie zo siete, zvyšovania prevádzkovej efektívnosti a prípravy budov na pokročilé formy prediktívneho riadenia [1].

Táto práca vychádza z konkrétne definovaného zadania, ktorého cieľom je navrhnuť a natrénovať agenta schopného optimalizovať spotrebu energie v budove na základe predpovedí počasia a informácií o obsadenosti miestností.

Ako vhodné prístupy sú uvažované algoritmy Q-learning a Deep Deterministic Policy Gradient (DDPG). Po ich implementácii budú tieto metódy porovnané z viacerých hľadísk, konkrétne z pohľadu dosiahnutých úspor energie v porovnaní s fixnou riadiacou stratégiou, citlivosti na rôzne návrhy reward funkcie a času potrebného na dosiahnutie stabilného riešenia.

II. Špecifikácia zadania

Zadanie s názvom Energetická optimalizácia inteligentnej budovy je formulované ako úloha naučiť agenta využívať reinforcement learning optimalizovať spotrebu energie v budove na základe predpovedí počasia a informácií o obsadenosti miestností. Ako vhodné algoritmy boli určené Q-learning a Deep Deterministic Policy Gradient (DDPG).

Po implementácii jednotlivých prístupov majú byť ich prevádzkové vlastnosti porovnané z viacerých hľadísk:

- dosiahnuté úspory energie v porovnaní s fixnou riadiacou stratégiou,
- vplyv rôznych návrhov reward funkcie na správanie agenta,

- čas potrebný na dosiahnutie stabilného riešenia.

V praktickej rovine to znamená, že agent pracuje s vopred dostupnými informáciami, najmä s predikovanou vonkajšou teplotou, solárnym žiarením a obsadenosťou budovy, a na ich základe volí riadiace akcie vedúce k energeticky efektívnejšej prevádzke.

Z hľadiska tejto práce je dôležité zdôrazniť, že cieľom nie je iba samotné použitie metód reinforcement learningu, ale predovšetkým riešenie konkrétnej úlohy optimalizácie spotreby energie v budove, kde RL predstavuje nástroj riadenia.

III. Prostredie CityLearn

CityLearn predstavuje open-source simulačné prostredie určené pre reinforcement learning, zamerané na výskum koordinovaného energetického riadenia budov a mestských štvrtí. Umožňuje modelovanie jednotlivých budov spolu s ich riaditeľnými zariadeniami a energetickými subsystémami. Zároveň poskytuje štandardizované rozhranie pre definovanie observácií, akcií, odmeňovacej funkcie (reward) a vyhodnocovanie výkonnosti modelov.

Pre účely tejto práce je CityLearn obzvlášť vhodný, keďže umožňuje experimentovanie s rôznymi návrhmi reinforcement learning algoritmov v identickom simulačnom prostredí, pričom zabezpečuje konzistentný a porovnateľný spôsob ich evaluácie.

V prostredí CityLearn je každá budova reprezentovaná množinou pozorovaných veličín a množinou riaditeľných akcií. Medzi pozorovania patria napríklad predpovede počasia, solárne zisky, informácie o obsadenosti, cena elektrickej energie či aktuálne stavy energetických zásobníkov. Naopak, akčný priestor zahŕňa riadenie chladiacich systémov a v rozšírených konfiguráciách aj nabíjanie a vybíjanie tepelných alebo elektrických zásobníkov.

Ďalšou významnou výhodou prostredia CityLearn je možnosť hodnotiť výsledky pomocou interpretovateľných metrík, ako sú napríklad množstvo importovanej elektriny zo siete, kumulatívny reward či ukazovatele súvisiace s tepelným diskomfortom.

Vďaka tomu je prostredie vhodné nielen na samotný tréning agentov, ale aj na systematické porovnávanie naučených riadiacich politík s jednoduchými referenčnými stratégiami.

IV. Q-learning

A. Počiatkový návrh Q-learningu podľa zadania

Prvá implementácia bola navrhnutá tak, aby reflektovala zadanie a využívala iba predikované vstupy, konkrétne meteorologické údaje a obsadenosť budovy. Z týchto vstupov boli vytvorené inžinierske príznaky, ako trend teploty a solárneho žiarenia či binárna informácia o obsadenosti, čo znížilo dimenzionalitu a zvýšilo ich využiteľnosť pre riadenie. Akčný priestor bol zjednodušený na riadenie chladenia s tromi diskretnými úrovňami, aby sa predišlo nekonzistentnosti pri absencii informácií o stave zásobníkov. Reward funkcia penalizovala odber zo siete, pričom penalizácia bola zosilnená pri obsadenej budove a vyššej teplote, čím bol agent motivovaný k opatrnejšiemu riadeniu v kritických situáciách.

B. Formulácia tabuľkového Q-learningu

Počiatkový agent využíval tabuľkový Q-learning. Stavový priestor bol diskretizovaný na konečný počet intervalov (bínov) a akčný priestor bol taktiež zredukovaný na malý počet diskretných hodnôt riadenia chladenia.

Q-tabuľka následne uchovávala odhady kvality vykonania konkrétnej akcie v konkrétnom diskretnom stave. Počas tréningu agent volil akcie pomocou ϵ -greedy stratégie, ktorá kombinuje exploračnú a exploitačnú.

Hodnota ϵ sa postupne znižovala, pričom bol zároveň implementovaný adaptívny mechanizmus, ktorý ju dokázal dočasne zvýšiť v prípade stagnácie učenia, teda ak nedochádzalo k zlepšovaniu výkonu agenta.

Aktualizácia hodnôt sa riadila štandardnou temporal-difference (TD) formulou:

$$Q(s, a) \leftarrow Q(s, a) + \alpha \left[r + \gamma \max_{a'} Q(s', a') - Q(s, a) \right] \quad (1)$$

kde s označuje aktuálny diskretný stav, a zvolenú akciu, r prijatý reward, s' nasledujúci stav, α mieru učenia a γ diskontný faktor.

C. Evaluácia počiatkového riešenia




Fig. 1. Vývoj učenia a odmeny.

Zo záverov vyplynulo, že model dosahoval lepšie výsledky za cenu mierne zvýšeného diskomfortu. Počiatková formulácia síce zodpovedala zadaniu, no odhalila

obmedzenia najmä v podobe príliš minimalistickej stavovej reprezentácie, ktorá nepostačuje pri rozšírení problému o ďalšie zariadenia. Rozhodovanie o zásobníkoch či reakcia na cenové signály vyžadujú dostupnosť relevantných stavových informácií. Ukazuje sa preto, že výkon agenta nezávisí len od množstva dát, ale najmä od kvality a informatívnosti stavovej reprezentácie.

D. Prechod k rozšíreným Q-learning experimentom

Po vytvorení počiatkovej verzie nasledovali rozšírené Q-learning experimenty. Stavová reprezentácia bola rozšírená o ďalšie premenné, ako cena elektriny a stav nabitia zásobníkov.

Zároveň bol rozšírený akčný priestor tak, aby zahŕňal súčasné riadenie zásobníka teplej vody, elektrického zásobníka a chladiaceho systému.

V rozšírenom experimente bolo implementovaných 12 variantov reward funkcie, ktoré menia preferencie agenta pri nezmenenom stavovom a akčnom priestore. Väčšina variantov vychádza z penalizácie odberu elektriny zo siete, pričom sa líšia v tom, aké prevádzkové priority zvýrazňujú (napr. cena elektriny, teplotný komfort alebo stav zásobníkov).

- 1) WeatherOccupancyReward zvyšuje penalizáciu odberu pri obsadenej budove a vyššej teplote – agent sa učí aj z rozšíreného stavového priestoru.
- 2) GridImportOnlyReward je najjednoduchší baseline $r = -g$, ktorý penalizuje iba okamžitý import zo siete bez ohľadu na cenu, komfort, predikcie či stav zásobníkov. Slúži ako referenčná politika na porovnanie zlepšenia.
- 3) PricingAwareReward rozširuje penalizáciu o cenu elektriny a podporuje presun spotreby mimo drahých období.
- 4) ComfortAwareReward kombinuje energetický a komfortný cieľ, vrátane penalizácie prehrievania.
- 5) PeakShavingReward používa kvadratickú penalizáciu $r = -g^2$, ktorá výrazne trestá špičky a vyhladzuje záťaž.
- 6) SolarAlignmentReward upravuje penalizáciu podľa slnečnej iradiácie, čím podporuje spotrebu pri vyššej produkcii obnoviteľnej energie.
- 7) StorageManagementReward pracuje so stavom zásobníkov a cenou.
- 8) RampingPenaltyReward penalizuje prudké zmeny odberu a stabilizuje profil.
- 9) TimeOfUseReward používa hodinový profil: večer vyššia penalizácia (> 1), noc nižšia (< 1), nezávisle od ceny a zásobníkov.
- 10) SelfSufficiencyReward penalizuje import a odmeňuje export, čím podporuje energetickú sebestačnosť.
- 11) CombinedMultiObjectiveReward kombinuje viac cieľov do váženej funkcie.
- 12) NightPrechargeReward podporuje nabíjanie v noci a vybíjanie počas špičky.

E. Equations

Number equations consecutively. To make your equations more compact, you may use the solidus (/), the exp function, or appropriate exponents. Italicize Roman symbols for quantities and variables, but not Greek symbols. Use a long dash rather than a hyphen for a minus sign. Punctuate equations with commas or periods when they are part of a sentence, as in:

$$a + b = \gamma \quad (2)$$

Be sure that the symbols in your equation have been defined before or immediately following the equation. Use “(2)”, not “Eq. (2)” or “equation (2)”, except at the beginning of a sentence: “Equation (2) is . . .”

F. L^AT_EX-Specific Advice

Please use “soft” (e.g., `\eqref{Eq}`) cross references instead of “hard” references (e.g., (1)). That will make it possible to combine sections, add equations, or change the order of figures or citations without having to go through the file line by line.

Please don’t use the `{eqnarray}` equation environment. Use `{align}` or `{IEEEeqnarray}` instead. The `{eqnarray}` environment leaves unsightly spaces around relation symbols.

Please note that the `{subequations}` environment in L^AT_EX will increment the main equation counter even when there are no equation numbers displayed. If you forget that, you might write an article in which the equation numbers skip from (17) to (20), causing the copy editors to wonder if you’ve discovered a new method of counting.

Bib_T_EX does not work by magic. It doesn’t get the bibliographic data from thin air but from .bib files. If you use Bib_T_EX to produce a bibliography you must send the .bib files.

L^AT_EX can’t read your mind. If you assign the same label to a subsection and a table, you might find that Table I has been cross referenced as Table IV-B3.

L^AT_EX does not have precognitive abilities. If you put a `\label` command before the command that updates the counter it’s supposed to be using, the label will pick up the last counter to be cross referenced instead. In particular, a `\label` command should not go before the caption of a figure or a table.

Do not use `\nonumber` inside the `{array}` environment. It will not stop equation numbers inside `{array}` (there won’t be any anyway) and it might stop a wanted equation number in the surrounding equation.

G. Some Common Mistakes

- The word “data” is plural, not singular.
- The subscript for the permeability of vacuum μ_0 , and other common scientific constants, is zero with subscript formatting, not a lowercase letter “o”.
- In American English, commas, semicolons, periods, question and exclamation marks are located within

quotation marks only when a complete thought or name is cited, such as a title or full quotation. When quotation marks are used, instead of a bold or italic typeface, to highlight a word or phrase, punctuation should appear outside of the quotation marks. A parenthetical phrase or statement at the end of a sentence is punctuated outside of the closing parenthesis (like this). (A parenthetical sentence is punctuated within the parentheses.)

- A graph within a graph is an “inset”, not an “insert”. The word *alternately* is preferred to the word “alternately” (unless you really mean something that alternates).
- Do not use the word “essentially” to mean “approximately” or “effectively”.
- In your paper title, if the words “that uses” can accurately replace the word “using”, capitalize the “u”; if not, keep using lower-cased.
- Be aware of the different meanings of the homophones “affect” and “effect”, “complement” and “compliment”, “discreet” and “discrete”, “principal” and “principle”.
- Do not confuse “imply” and “infer”.
- The prefix “non” is not a word; it should be joined to the word it modifies, usually without a hyphen.
- There is no period after the “et” in the Latin abbreviation “et al.”.
- The abbreviation “i.e.” means “that is”, and the abbreviation “e.g.” means “for example”.

An excellent style manual for science writers is [7].

H. Authors and Affiliations

The class file is designed for, but not limited to, six authors. A minimum of one author is required for all conference articles. Author names should be listed starting from left to right and then moving down to the next line. This is the author sequence that will be used in future citations and by indexing services. Names should not be listed in columns nor group by affiliation. Please keep your affiliations as succinct as possible (for example, do not differentiate among departments of the same organization).

I. Identify the Headings

Headings, or heads, are organizational devices that guide the reader through your paper. There are two types: component heads and text heads.

Component heads identify the different components of your paper and are not topically subordinate to each other. Examples include Acknowledgments and References and, for these, the correct style to use is “Heading 5”. Use “figure caption” for your Figure captions, and “table head” for your table title. Run-in heads, such as “Abstract”, will require you to apply a style (in this case, italic) in addition to the style provided by the drop down menu to differentiate the head from the text.

Text heads organize the topics on a relational, hierarchical basis. For example, the paper title is the primary text head because all subsequent material relates and elaborates on this one topic. If there are two or more sub-topics, the next level head (uppercase Roman numerals) should be used and, conversely, if there are not at least two sub-topics, then no subheads should be introduced.

J. Figures and Tables

a) Positioning Figures and Tables: Place figures and tables at the top and bottom of columns. Avoid placing them in the middle of columns. Large figures and tables may span across both columns. Figure captions should be below the figures; table heads should appear above the tables. Insert figures and tables after they are cited in the text. Use the abbreviation “Fig. 2”, even at the beginning of a sentence.

TABLE I
Table Type Styles

Table Head	Table Column Head		
	Table column subhead	Subhead	Subhead
copy	More table copy ^a		

^aSample of a Table footnote.




Fig. 2. Example of a figure caption.

Figure Labels: Use 8 point Times New Roman for Figure labels. Use words rather than symbols or abbreviations when writing Figure axis labels to avoid confusing the reader. As an example, write the quantity “Magnetization”, or “Magnetization, M”, not just “M”. If including units in the label, present them within parentheses. Do not label axes only with units. In the example, write “Magnetization (A/m)” or “Magnetization {A[m(1)]}”, not just “A/m”. Do not label axes with a ratio of quantities and units. For example, write “Temperature (K)”, not “Temperature/K”.

Acknowledgment

The preferred spelling of the word “acknowledgment” in America is without an “e” after the “g”. Avoid the stilted expression “one of us (R. B. G.) thanks ...”. Instead, try “R. B. G. thanks ...”. Put sponsor acknowledgments in the unnumbered footnote on the first page.

References

Please number citations consecutively within brackets [1]. The sentence punctuation follows the bracket [2]. Refer simply to the reference number, as in [3]—do not use “Ref. [3]” or “reference [3]” except at the beginning of a sentence: “Reference [3] was the first ...”

Number footnotes separately in superscripts. Place the actual footnote at the bottom of the column in which it was cited. Do not put footnotes in the abstract or reference list. Use letters for table footnotes.

Unless there are six authors or more give all authors’ names; do not use “et al.”. Papers that have not been published, even if they have been submitted for publication, should be cited as “unpublished” [4]. Papers that have been accepted for publication should be cited as “in press” [5]. Capitalize only the first word in a paper title, except for proper nouns and element symbols.

For papers published in translation journals, please give the English citation first, followed by the original foreign-language citation [6].

References

- [1] J. R. Vázquez-Canteli, Z. Nagy, S. Dey, and G. Henze, “CityLearn: Standardizing Research in Multi-Agent Reinforcement Learning for Demand Response and Urban Energy Management,” The University of Texas at Austin and University of Colorado Boulder.
- [2] J. Clerk Maxwell, A Treatise on Electricity and Magnetism, 3rd ed., vol. 2. Oxford: Clarendon, 1892, pp.68–73.
- [3] I. S. Jacobs and C. P. Bean, “Fine particles, thin films and exchange anisotropy,” in Magnetism, vol. III, G. T. Rado and H. Suhl, Eds. New York: Academic, 1963, pp. 271–350.
- [4] K. Elissa, “Title of paper if known,” unpublished.
- [5] R. Nicole, “Title of paper with only first word capitalized,” J. Name Stand. Abbrev., in press.
- [6] Y. Yorozu, M. Hirano, K. Oka, and Y. Tagawa, “Electron spectroscopy studies on magneto-optical media and plastic substrate interface,” IEEE Transl. J. Magn. Japan, vol. 2, pp. 740–741, August 1987 [Digests 9th Annual Conf. Magnetics Japan, p. 301, 1982].
- [7] M. Young, The Technical Writer’s Handbook. Mill Valley, CA: University Science, 1989.
- [8] D. P. Kingma and M. Welling, “Auto-encoding variational Bayes,” 2013, arXiv:1312.6114. [Online]. Available: <https://arxiv.org/abs/1312.6114>
- [9] S. Liu, “Wi-Fi Energy Detection Testbed (12MTC),” 2023, gitHub repository. [Online]. Available: <https://github.com/liustone99/Wi-Fi-Energy-Detection-Testbed-12MTC>
- [10] “Treatment episode data set: discharges (TEDS-D): concatenated, 2006 to 2009.” U.S. Department of Health and Human Services, Substance Abuse and Mental Health Services Administration, Office of Applied Studies, August, 2013, DOI:10.3886/ICPSR30122.v2
- [11] K. Eves and J. Valasek, “Adaptive control for singularly perturbed systems examples,” Code Ocean, Aug. 2023. [Online]. Available: <https://codeocean.com/capsule/4989235/tree>

IEEE conference templates contain guidance text for composing and formatting conference papers. Please ensure that all template text is removed from your conference paper prior to submission to the conference. Failure to remove the template text from your paper may result in your paper not being published.